Report of question 6 - CNN for CIFAR10

در این قسمت از تمرین میخواهیم 50000 عکس از 10 کلاس را اموزش دهیم. برای پیاده سازی شبکه عصبی از لایه های کانولوشن و پولینگ استفاده می کنیم تا پارامترهای کمتری داشته باشیم تا بتوانیم به راحتی ترین کنیم. علاوه بر این، ما اثرات تعداد بلوک ها و لایه های پنهان را بررسی می کنیم و از روش های دراپ اوت و توقف زودهنگام استفاده می کنیم تا دقت بالاتری به دست آوریم و این تغییرات را روی نمودار نمایش دهیم.

در ابتدا باید دیتا را به صورتی که میخواهیم تبدیل کنیم. یکی از کارهایی که میکنیم وان هات است. در لیبل ها به وان هات به جای نمایش تعداد هر کلاس آرایه ای با طول تعداد کلاس ها ایجاد می شود و در آن احتمال وجود هر کلاس را می توان نشان داد که به این صورت می شود که تمام عناصر آرایه صفر هستند و شاخصی که عکس به آن می رسد متعلق به آن کلاس یکی است یا همه عناصر عددی بین 0 یا 1 هستند که احتمال هر کلاس در آن عکس نشان داده شده است. مجموع همه اعداد باید برابر با 1 باشد.

Reshape dataset

convert labels to one-hot encoding

from tensorflow.keras.utils import to_categorical

cat_y_trainData = to_categorical(Y_trainData, num_classes=10)

cat_y_testData = to_categorical(Y_testData, num_classes=10)

قسمت اول: ساخت مدل ساده سی ان ان

در این قسمت سه بلوک متشکل از تنها دو کانولوشن و یک مکس پولینگ ایمپلیمنت میشود. در نهایت همه این بخش ها فلت شده و توسط فقط یک لایه ی نهایی فولی کانکتد خروجی میدهند.

♣ Homework2.ipynb ☆ File Edit View Insert Runtime Tools Help All changes saved + Code + Text ≣ Q input = Input(shape=(32, 32, 3)) x = Conv2D(32, (3, 3), activation='relu', padding='same')(input) {*x*} x = Conv2D(32, (3, 3), activation='relu', padding='same')(x)x = MaxPool2D((2, 2))(x)x = Conv2D(64, (3, 3), activation='relu', padding='same')(x) x = Conv2D(64, (3, 3), activation='relu', padding='same')(x) x = MaxPool2D((2, 2))(x)x = Conv2D(128, (3, 3), activation='relu', padding='same')(x) x = Conv2D(128, (3, 3), activation='relu', padding='same')(x) x = MaxPool2D((2, 2))(x)x = Flatten()(x)x = Dropout(0.2)(x)x = Dense(units=128)(x)x = ReLU()(x)x = Dense(units=10)(x)predictions = Activation(activation='softmax')(x) <> \equiv our_CNN_model = Model(input, predictions) >_

CO ← Homework2.ipynb ☆

File Edit View Insert Runtime Tools Help All changes saved

```
+ Code + Text
∷
  our_CNN_model.fit(x=X_trainData, y=cat_y_trainData, epochs=35, batch_size=32,
         validation_data=(X_testData, cat_y_testData))
Q
    Epoch 8/35
{x}
    1563/1563 [=
            ==========] - 10s 6ms/step - loss: 0.2925 - accuracy: 0.8973 - val loss: 0.8084 - val accuracy: 0.7692
    Epoch 9/35
    1563/1563 [=
           :=========] - 10s 6ms/step - loss: 0.2715 - accuracy: 0.9037 - val loss: 0.8489 - val accuracy: 0.7678
Epoch 10/35
    Epoch 11/35
    Epoch 12/35
    Epoch 13/35
    1563/1563 [=
            ==========] - 9s 6ms/step - loss: 0.2270 - accuracy: 0.9205 - val_loss: 0.8984 - val_accuracy: 0.7717
    Epoch 14/35
    1563/1563 [==
           Epoch 15/35
    1563/1563 [=
           Epoch 16/35
    Fnoch 17/35
    Epoch 18/35
    1563/1563 [==
           <>
    Epoch 19/35
    1563/1563 [==
           ===
    Epoch 20/35
    1563/1563 [==
          >_
    Epoch 21/35
```

✓ 2s completed at 9:37 AM

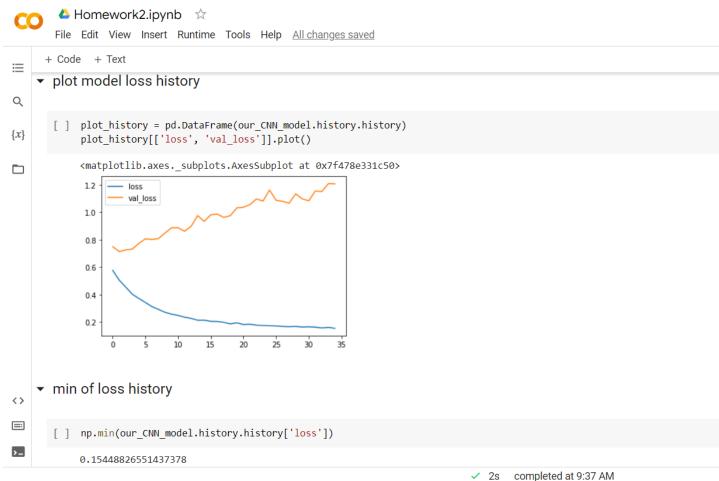
CO ♣ Homework2.ipynb ☆

File Edit View Insert Runtime Tools Help All changes saved

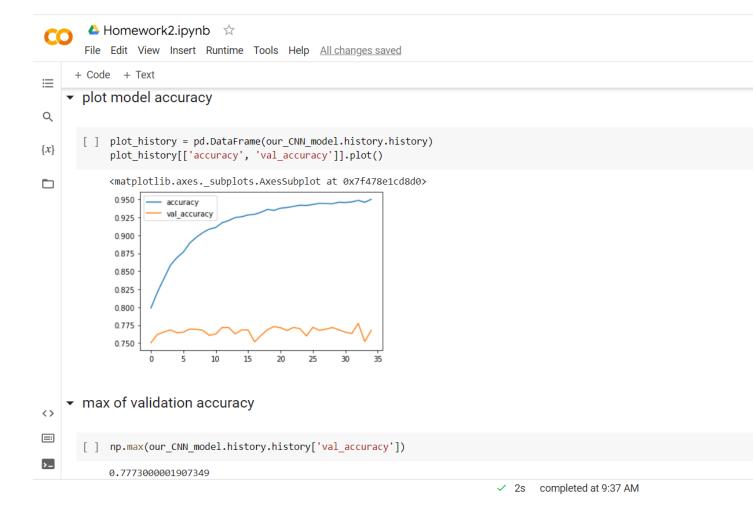
```
+ Code + Text
∷
  Q
   Epoch 25/35
   1563/1563 [=:
        Epoch 26/35
{x}
   Epoch 27/35
Epoch 28/35
   Epoch 29/35
        1563/1563 [=
   Epoch 30/35
   1563/1563 [==
         =========] - 9s 6ms/step - loss: 0.1640 - accuracy: 0.9461 - val_loss: 1.0984 - val_accuracy: 0.7685
   Epoch 31/35
   1563/1563 [=
         ==========] - 9s 6ms/step - loss: 0.1655 - accuracy: 0.9458 - val_loss: 1.0841 - val_accuracy: 0.7652
   Epoch 32/35
   1563/1563 [==
       Epoch 33/35
        .
1563/1563 [=
   Epoch 34/35
   Epoch 35/35
   <keras.callbacks.History at 0x7f478e337b50>
<>
■ v plot model loss history
>_
```

✓ 2s completed at 9:37 AM

همان طور که میبینیم مدل ترین میشود اما در نهایت فرایند کند شده و به اور فیتینگ میخورد. این نشان میدهد که با تغییر معماری میشود انرا بهینه تر کرد. برای روشن شدن وضعیت مدل ساده نمودار های ان را رسم میکنیم.



میبینیم که ابتدا اختلاف در حال کم شدن بود یعنی مدل خوب بود. الی به دلیل اورفیتینگ اختلاف ولیدیشن دیتا و دیتای ترین زیاد شد که این بد است. همین اتفاق را برای اکیوریسی نیز داریم.



در نهایت چک میکنیم که ببینیم مقادیر اکیوریسی داده ها چقدر اختلاف با بیشترین اکیوریسی ولیدیشن دیتا دارد.

قسمت دوم: پیاده سازی لایه های پنهان با عمق بیشتر

```
♣ Homework2.ipynb ☆
       File Edit View Insert Runtime Tools Help All changes saved
     + Code + Text
∷
       input = Input(shape=(32, 32, 3))
Q
           x = Conv2D(filters=32, kernel_size=(3, 3), strides=1, padding='same')(input)
{X}
           x = MaxPool2D(pool_size=(2, 2), strides=2, padding='same')(x)
           x = Conv2D(filters=64, kernel_size=(3, 3), strides=1, padding='same')(x)
x = ReLU()(x)
            x = MaxPool2D(pool size=(2, 2), strides=2, padding='same')(x)
           x = Conv2D(filters=128, kernel_size=(3, 3), strides=1, padding='same')(x)
           x = ReLU()(x)
           x = MaxPool2D(pool_size=(2, 2), strides=2, padding='same')(x)
           x = Conv2D(filters=256, kernel_size=(3, 3), strides=1, padding='same')(x)
           x = MaxPool2D(pool_size=(2, 2), strides=2, padding='same')(x)
           x = Conv2D(filters=512, kernel\_size=(3, 3), strides=1, padding='same')(x)
           x = ReLU()(x)
           x = MaxPool2D(pool_size=(2, 2), strides=2, padding='same')(x)
<>
            #globalaveragepooling
            x = GlobalAveragePooling2D()(x)
==:
           x = Dense(units=128)(x)
>_
            x = ReLU()(x)
                                                                                2s completed at 9:37 AM
              x = Dense(units=32)(x)
```

```
x = Dense(units=32)(x)
x = ReLU()(x)
x = Dense(units=10)(x)
predictions = Activation(activation='softmax')(x)

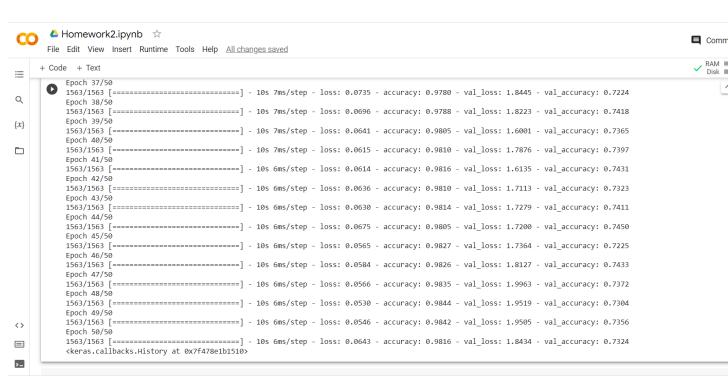
our_CNN_model2 = Model(input, predictions)
```

در این لایه تعداد بلوک های لایه های پنهان را افزایش دادیم. از طرف دیگر تعداد لایه های فولی کانکتد را هم افزایش دادیم تا مدل عمیق تر شود . سپس مدل را دوباره ترین کردیم.

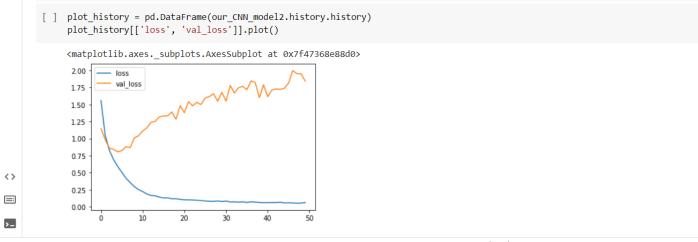
CO ♣ Homework2.ipynb ☆

File Edit View Insert Runtime Tools Help All changes saved

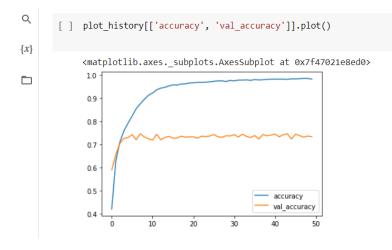
```
+ Code + Text
\equiv
       омп_енит_шометъттъелл л_енитирием, у сме_у_енитирием, еросно обу омеен_отъе оъ, читъмистон_мием (л_есосрасм, сме_у_есосрасм),
      Fnoch 1/50
Q
      1563/1563 [==
                   Fnoch 2/50
\{x\}
       1563/1563 [=
                   =========] - 10s 7ms/step - loss: 1.0516 - accuracy: 0.6266 - val_loss: 0.9858 - val_accuracy: 0.6554
       Epoch 3/50
       1563/1563 [==
              :============================= ] - 10s 6ms/step - loss: 0.8297 - accuracy: 0.7104 - val_loss: 0.8603 - val_accuracy: 0.7035
Epoch 4/50
      1563/1563 [==
                 Epoch 5/50
      1563/1563 [==
              Epoch 6/50
      1563/1563 [=
                    =========] - 10s 7ms/step - loss: 0.5053 - accuracy: 0.8221 - val_loss: 0.8228 - val_accuracy: 0.7413
      Epoch 7/50
       1563/1563 [
                   =========] - 10s 6ms/step - loss: 0.4203 - accuracy: 0.8542 - val_loss: 0.8807 - val_accuracy: 0.7194
      Epoch 8/50
       1563/1563 [==
                 Epoch 9/50
                   :========] - 10s 6ms/step - loss: 0.2976 - accuracy: 0.8946 - val_loss: 1.0104 - val_accuracy: 0.7312
       1563/1563 [=
      Epoch 10/50
      Epoch 11/50
                     ========] - 10s 6ms/step - loss: 0.2243 - accuracy: 0.9213 - val loss: 1.1103 - val accuracy: 0.7180
      1563/1563 [=
      Fnoch 12/50
       1563/1563 [==
                   <>
       Epoch 13/50
       1563/1563 [=====
                ==:
       Epoch 14/50
       1563/1563 [==
                 >_
      Epoch 15/50
       .
1563/1563 [-
                             -- 1 - 10c 6mc/stan - locc: 0 1/21 - accuracy: 0 0522 - val locc: 1 2186 - val accuracy: 0 7226
                                               2s completed at 9:37 AM
```



همان طور که دیده میشود نورون در عین حال که نورون های بیشتری را شامل میشد و از گلوبال اورج پولینگ استفاده شد ولی بهبودی در ولیدیشن اکیوریسی ایجاد نشد و حتی مدل بدتر هم شد.



✓ 2s completed at 9:37 AM



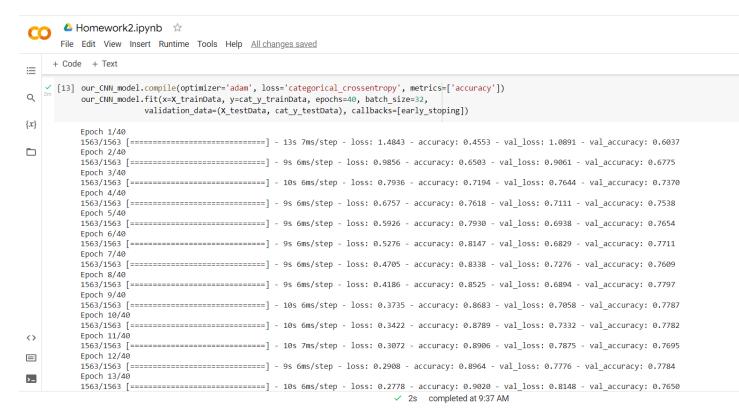
در این مسئله چون تعداد نمونه های ما به اون صورت زیاد نیست وقتی لایه هارا زیاد میکنیم در هر سری لایه کانولوشن می اید یک بخشی از فیچرها را بدست میاورد. وقتی لایه ها بیشتر شود فیچر ها ریزتر میشود و ممکن است در ترین شدن یا به اورفیتینگ برسیم یا اینکه نتیجه عکس دهد و اکیوریسی کم شود. از طرف دیگر چون ار جی بی است اگر لایه از یک حدی کمتر شود نمیتانیم فیچر های درستی استخراج کنیم.

در مرحله ی فلت کردن باز هم اگر لایه های فولی کاکنتد اضافه کنیم،چون فیچر هایی که لایه اخر کانولوشن اخر بدست اورده است به ان صورت زیاد نیست در هر ایپاک اپدیت های درستی نمیدهد.



قسمت سوم: استفاده از معماری های دیگر برای بهینه شدن مدل

در این قسمت با استفاده از ارلی استاپینگ مانع از اور فیتینگ میشویم. به این صورت که یا روی ماکیسمم اکیوریسی میگذاریم و تا ده تا ایپاک برای مثال چک میکنیم که اگر بیشتر از ان نشد ترینینگ را متوقف کند یا روی مینیمم مقدار لاس قرار میدهیم.



در پلات ها میبینیم که تقریبا قبل از اورفیتیگ شدن فرایند ترین شدن متوقف شده و داده ها اورفیت نشدند.





و در نهایت یکی از بهترین ولیدیشن اکیوریسی هارا خواهیم داشت:



میتوانیم برای این مدل کانفیوژن ماتریکس تشکیل دهیم.

Homework File Edit View		e Tools H	elp <u>All chan</u>	g <u>es saved</u>			
+ Code + Text							
▼ printing class	sification re	oort					
} v [20] from sklea	rn.metrics im	port confus	sion_matrix	, classification	_report		
y [21] print(clas	sification_re	port(Y_test	:Data, pred:	ictions_sparse))			
	precision	recall	f1-score	support			
	0 0.75	0.84	0.79	1000			
	1 0.86	0.91	0.88	1000			
	2 0.72	0.62	0.67	1000			
	3 0.60	0.65	0.62	1000			
	4 0.68	0.80	0.74	1000			
	5 0.78		0.67	1000			
	6 0.86		0.81	1000			
	7 0.76		0.80	1000			
	8 0.90		0.87	1000			
	9 0.84	0.87	0.86	1000			
accura	су		0.77	10000			
macro a	•	0.77	0.77	10000			
weighted a	vg 0.78	0.77	0.77	10000			
•							
▼ use cinfusior	n matrix						

✓ 2s completed at 9:37 AM

```
♣ Homework2.ipynb ☆
      File Edit View Insert Runtime Tools Help All changes saved
     + Code + Text
≣
    use cinfusion matrix
\{x\}

[22] confusion_matrix(Y_testData, predictions_sparse)
array([[843, 20, 27, 14, 19,
                                       0, 0, 13, 38, 26],
                                      1,
                [ 10, 914, 1, 1, 2,
                                          5,
                                               1, 15, 50],
                [ 97, 5, 620, 50, 93, 37, 48, 31,
                                                   7, 12],
                                              56,
                [ 25, 9, 49, 650, 77, 76, 34,
                [ 18, 1, 44, 44, 799, 11, 20,
                14, 4, 46, 199, 54, 579, 10, 89,
                [ 11, 4, 38, 83, 74, 16, 756,
                                          1,849,
                [ 15, 4, 22, 28, 46, 16,
                [ 68, 40, 11, 11, 4, 1, 1,
                                              5, 835, 24],
                                 5,
                [ 27, 66, 4, 9,
                                      4,
                                          1,
                                                8, 10, 866]])
```

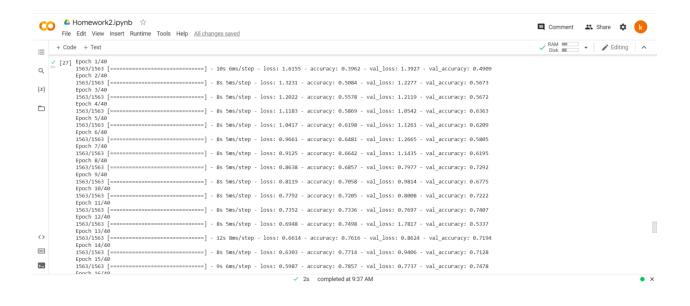
این ماتریکس به این صورت است که به غیر از قطر که مقادیر بالایی دارد هر رقمی غیر این ها مقدار پرتی داشته باشد یعنی مدل در انجا ها خوب تشخیص نداده است. برای مثال در این مدل چون سگ و گربه در کلاس 4 و 6 که سگ و گربه هستند (اعداد 199و 83) نتوانسته به خوبی از هم تشخیص دهد و مقادیر بالاتری گرفته اند.

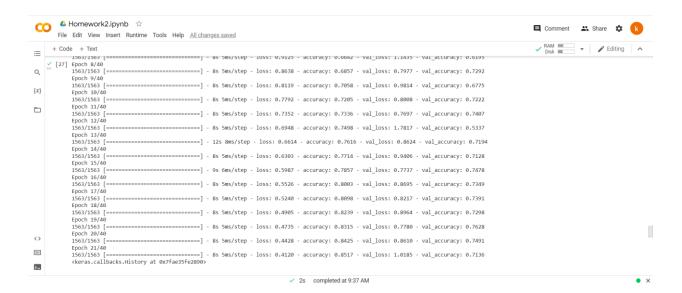
قسمت چهارم: استفاده از بچ نرمالیزیشن و تکنیک دراپ اوت

در بچ نرمالیزیشن میدانیم به این صورت عمل میشود که بعد از هر لایه کانولوشن دیتاهارا در رنج خاصی نرمال کرد و به تابع رلو میداد تا دیتای پرت زیادی تولید نشود و از طرفی دیتا از دست نرود.

```
♣ Homework2.ipynb ☆
       File Edit View Insert Runtime Tools Help All changes saved
     + Code + Text
\equiv
    [24] input = Input(shape=(32, 32, 3))
Q
           x = Conv2D(filters=32, kernel_size=(5, 5), strides=1, padding='same')(input)
            x = BatchNormalization()(x)
{x}
           x = ReLU()(x)
           x = MaxPool2D(pool_size=(2, 2), strides=2, padding='same')(x)
x = Conv2D(filters=64, kernel_size=(3, 3), strides=1, padding='same')(x)
            x = BatchNormalization()(x)
            x = ReLU()(x)
            x = MaxPool2D(pool_size=(2, 2), strides=2, padding='same')(x)
           x = Conv2D(filters=128, kernel_size=(3, 3), strides=1, padding='same')(x)
           x = BatchNormalization()(x)
            x = ReLU()(x)
            x = MaxPool2D(pool_size=(2, 2), strides=2, padding='same')(x)
           x = Flatten()(x)
            x = Dense(units=128)(x)
           x = ReLU()(x)
            x = Dropout(0.3)(x)
            x = Dense(units=10)(x)
<>
            predictions = Activation(activation='softmax')(x)
\equiv
            our_CNN_model3 = Model(input, predictions)
>_
```

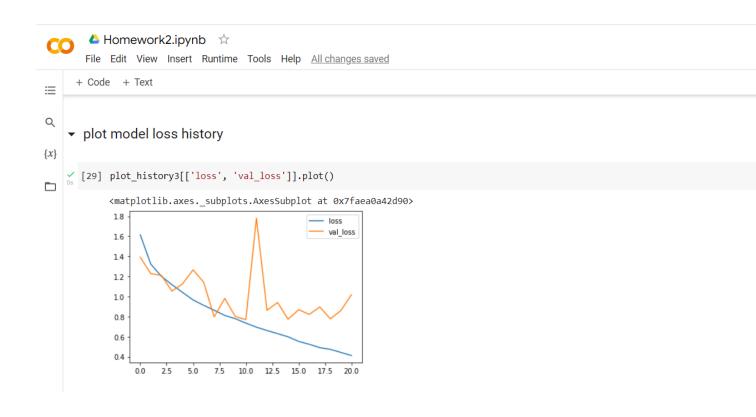
2s completed at 9:37 AM





همان طور که میبینیم ارلی استاپینگ مانع از اورفیتیگ میشود و از طرف دیگر اکیوریسی خوبی داریم که با ولیدیشن اکیوریسی اختلاف زیادی ندارد پس مدل ما مدل خوبی با این تغییرات شد.

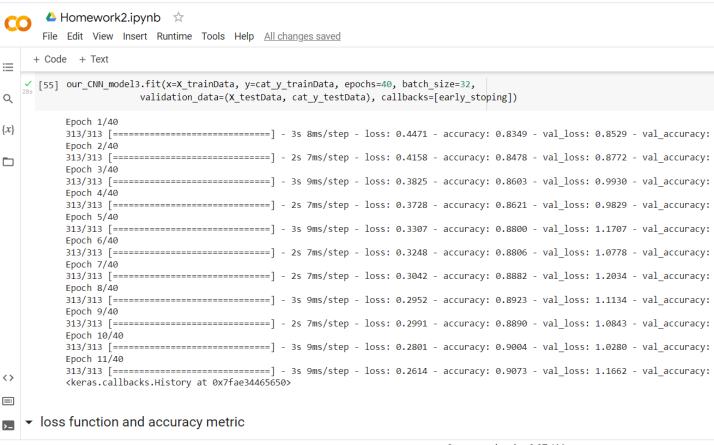
♣ Homework2.ipynb ☆ File Edit View Insert Runtime Tools Help All changes saved + Code + Text ∷ Q ▼ plot model loss history {*x*} [29] plot_history3[['loss', 'val_loss']].plot() <matplotlib.axes._subplots.AxesSubplot at 0x7faea0a42d90> -- val_loss 1.6 1.4 1.2 1.0 0.8 0.6 0.4 10.0 12.5 15.0 17.5 0.0 2.5 5.0 7.5



و در نهایت اگر ولیدیشن اکیوریسی را حساب کنیم عدد خوبی بدست خواهد امد.

قسمت پنجم: استفاده از قسمتی از داده

در برخی مسائل میبینیم که استفاده از بخشی از دیتا میتواند دقت مارا بالا ببرد در حالی که تعداد دیتای ما کمتر است و ترین کمتر طول میکشد. در این قسمت از کد میتوانیم ببینیم که با اینکه بخشی از دیتا را در نظر گرفتیم دقت خوبی به ما میدهد. البته این بخش کوچک تر از دیتا نمیتواند در این مسئله خیلی کوچک باشد چون ابتدای ان سیاه سفید است و باید به نوع دیتا مرتبط است.



```
♣ Homework2.ipynb ☆
       File Edit View Insert Runtime Tools Help All changes saved
      + Code + Text
\equiv
    ▼ loss function and accuracy metric
Q
    56 | plot_history3 = pd.DataFrame(our_CNN_model3.history.history)
{x}
            plot_history3[['accuracy', 'val_accuracy']].plot()
            <matplotlib.axes._subplots.AxesSubplot at 0x7fae34c2abd0>
accuracy
             0.90
                     val_accuracy
             0.85
             0.80
             0.75
             0.70
                                                         10
```

